Physische Datenorganisation

Detailierte Struktur eines DBMS

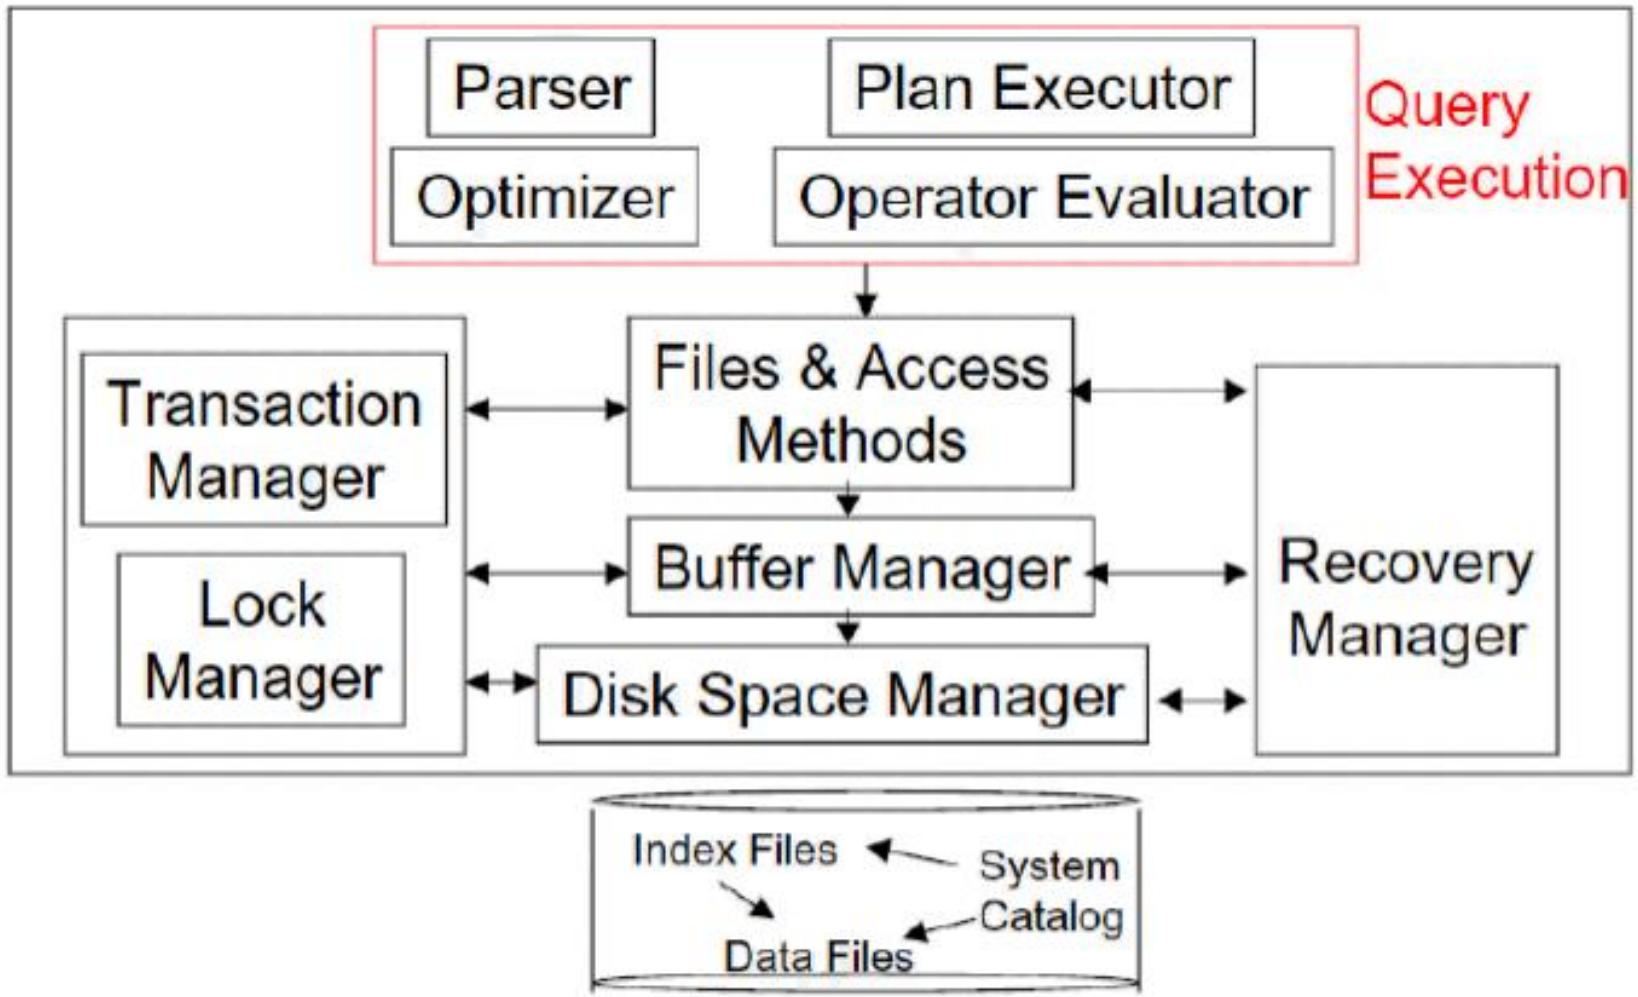

Speichermedien

- Man unterscheidet meist drei Stufen von Speichermedien:
  - **Primärspeicher/Hauptspeicher**: sehr teuer, sehr schnell, eher klein (im Vergleich zur benötigten Datenmenge)
    - Es ist möglich auf beliebige Adressen direkt zuzugreifen → die Granularität des Hauptspeichers ist sehr fein
  - **Sekundärspeicher**: Festplatte: Zugriff zu Daten ist langsamer, bietet mehr Platz, günstiger
    - Ein direkter Zugriff ist möglich, aber mit einer gröberen Granularität
    - Die kleinste Einheit auf eine Festplatte ist ein **Block**
    - In DBMS wird meistens als kleinste Einheit eine **Seite** verwendet
  - **Archivspeicher/Tertiärspeicher**

Platten und Dateien

- DBMS speichert Informationen auf externen Datenträgern: Magnetplatten (Hard Disks), Bänder (tapes)
- Zwei Hauptoperationen:
  - READ: Datentransfer von Platte (Sekundärspeicher) in den Hauptspeicher (RAM)
  - WRITE: Datentransfer vom RAM auf Platte
- Beides sind Operationen mit hohen Kosten im Vergleich zu in-memory Operationen und müssen deshalb sorgfältig geplant werden

  → Bedeutende Auswirkungen auf den Entwurf eines DBMS

Warum nicht alles im Primärspeicher behalten?

- Problem:
  - zu hohe Kosten
  - Primärspeicher (RAM) ist flüchtig/volatile - wir möchten Daten zwischen einzelnen Programmläufen speichern → wir brauchen persistente Daten
- Flüchtig/volatile = der Inhalt des Speichers steht nur zur Laufzeit des Systems zur Verfügung
- Typische Speicherhierarhie:
  - Primärspeicher – für die Daten, die an einem bestimmten Moment benutzt werden
    - **Cache** für sehr schnellen Datenzugriff
    - **Main Memory (RAM)** für häufig genutzte Daten
  - Sekundärspeicher – Disks für die aktuelle Datenbank
    - Flash Memory (SSD)
    - Festplatte – auf Magnetscheiben gespeichert
    - Optische Datenträger (CD-ROM, DVD, Blu-ray)
  - Archivspeicher/Band – für die Archievierung älterer Versionen der Datenbank oder Sicherheitskopien für Recovery-Zwecke

Speicherhierarhie

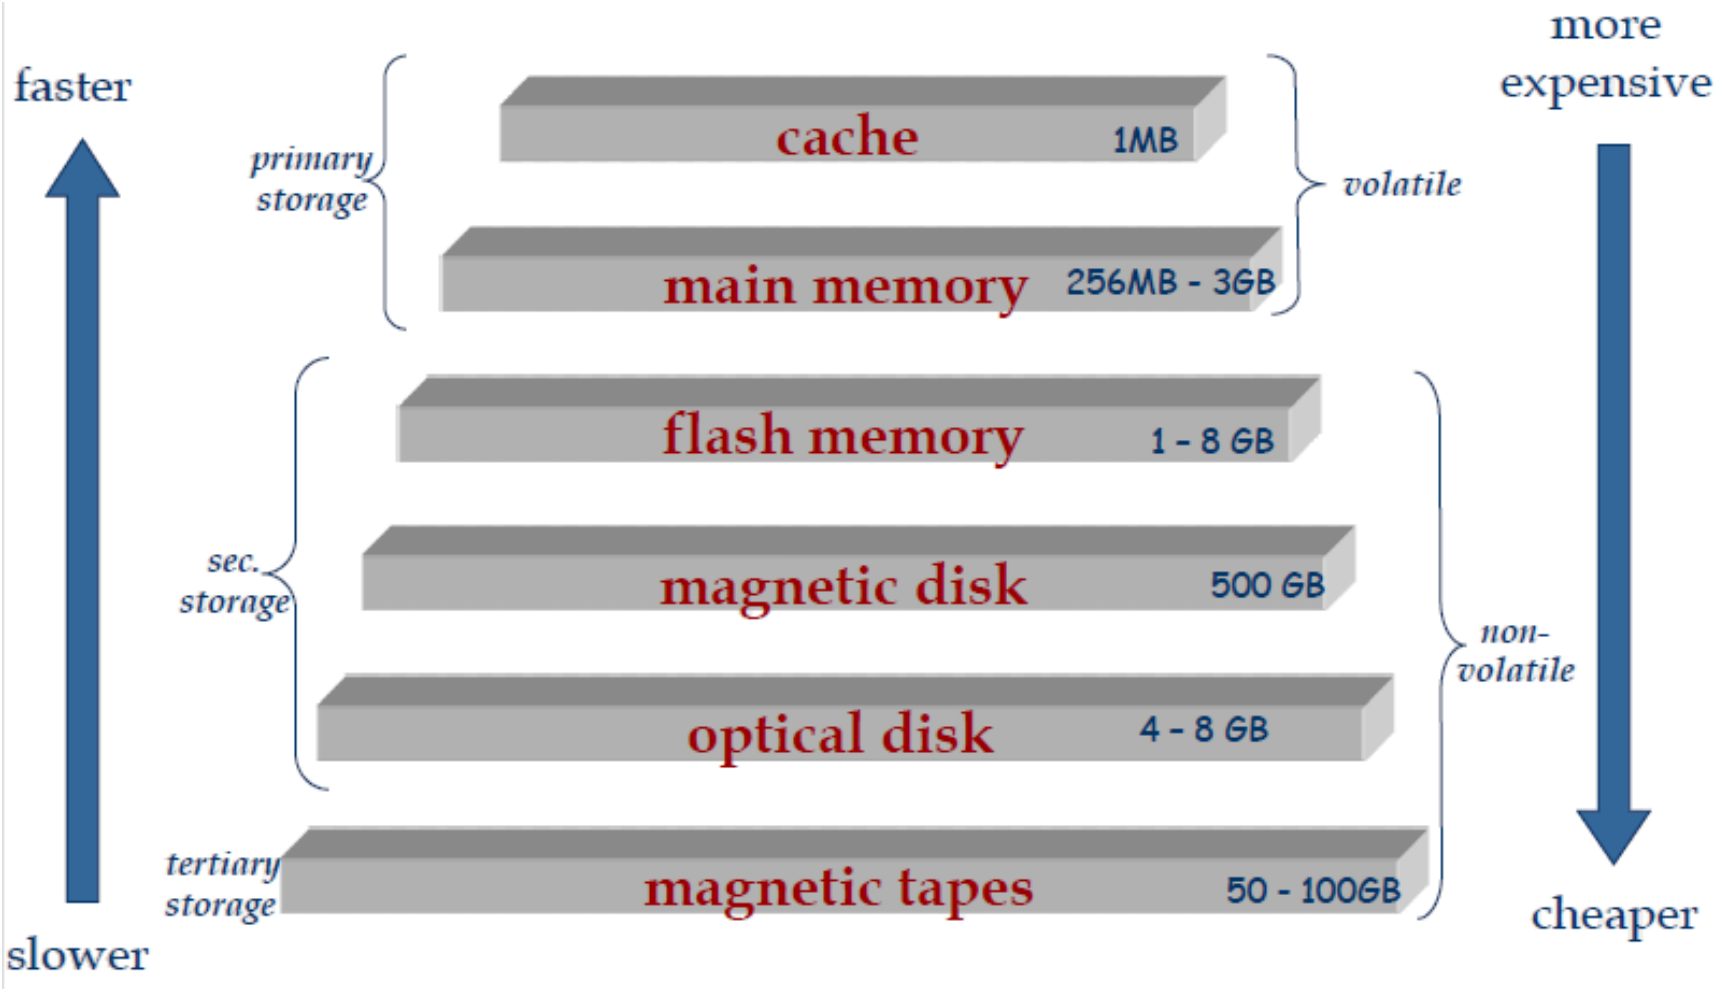

Platten

- Bevorzugtes Speichermedium für Sekundärspeicher
- Hauptvorteil gegenüber Bänder: Direktzugriff (random access)
- Daten werden gespeichert und gelesen in Einheiten, genannt Blöcke oder Seiten/Pages
- Blöcke werden in konzentrischen Ringen angeordnet = Spuren (Tracks)
- Spuren können auf beiden Seiten der Platten angelegt werden
- Im Gegensatz zum RAM hängt die Zeit zum Auffinden eines Blocks vom Speicherort auf der Platte ab

  → die relative Platzierung von Blöcke auf der Platte hat einen großen Einfluß auf die Performance des DBMS

Komponenten einer Platte

- Plattenumdrehung (ca. 90/Sek)
- Zugriffskamm wird hinein- oder hinausbewegt, um den Schreib/Lesekopf auf die gewünschte Spur zu positionieren
- Zylinder = alle übereinander angeordneten Spuren von Plattenoberflächen
- Nur ein Schreib/Lesekopf arbeitet zu einem bestimmten Zeitpunkt
- Blockgröße ist das Vielfache einer Sektorgröße (welche fest ist)

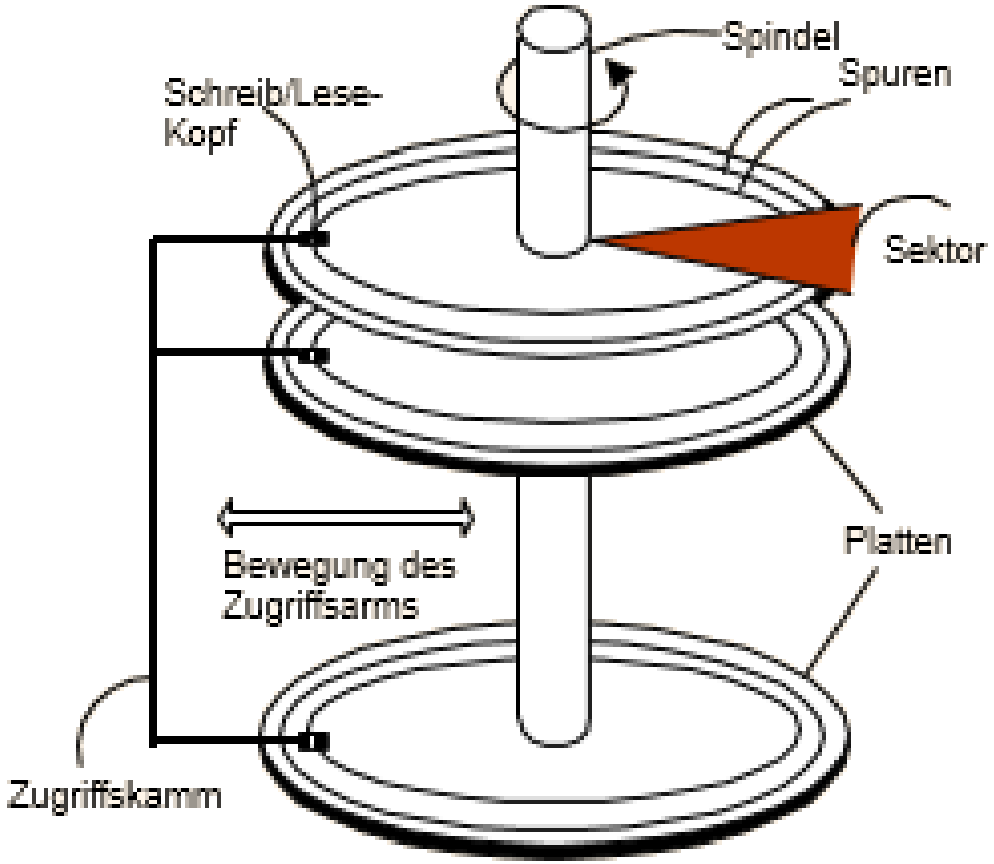

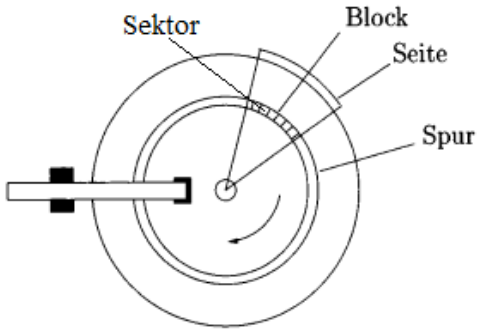

Aufsicht

Zugriff auf eine Page

- Addressierung von Blöcken über Zylinder-, Spur- und Sektor-Nr
- Zugriffskamm muss über entsprechenden Zylinder geführt werden,auf den Sektor warten, der irgendwann vorbeirotiert und schließlich den Blockinhalt lesen und übertragen
- Zugriffszeit (read/write) auf einen Block:
  - Zugriffsbewegungszeit (seek time) – Bewegung der Zugriffsarme, um den Schreib/Lesekopf auf der richtigen Spur zu positionieren
  - Umdrehungswartezeit (latency time, rotational delay) – Warten bis der gesuchte Block am Kopf vorbeirotiert
  - Übertragungszeit (transfer time) – tatsächlicher Transport der Daten von/zu der Plattenoberfläche

Zugriff auf eine Page

- Seek time und Umdrehungswartezeit dominieren
  - Seek time: zwischen 1 und 20 ms
  - Umdrehungswartezeit: zwischen 0 und 10 ms
  - Übertragungzeit – 1 ms/4 KB Page
- Reduzierung der I/O Kosten heißt Seek time und Umdrehungswartezeit verringern!
- Hardware- vs. Software-Lösungen

Anordnung von Pages auf einer Platte

- „Next“ Block – Konzept
  - Blöcke auf der gleichen Spur, gefolgt von
  - Blöcken auf dem gleichen Zylinder, gefolgt von
  - Blöcken auf benachbartem Zylinder
- Blöcke sollten in einer Datei sequentiell angeordnet sein (mit „next“), um die Zugriffsbewegungszeit und die Umdrehungswartezeit zu minimieren
- Prefetching – derzeit noch nicht (aber vielleicht in Kürze) benötigte Pages werden gleich mit gelesen
- Es gilt: Sequentiellen Lese (Scan) ist immer viel schneller als wahlfreier Zugriff (Random Access)

RAID (Redundant Array of Independent Disks)

- Disk Array: Anordnung mehrerer Platten, die in Abstraktion als einzige große Platte angesehen werden können (Steuerung erfolgt durch Controller) – es ist billiger mehrere kleinere Disks zu benutzen
- Ziele:
  - Steigerung der Performance durch Parallelität des Zugriffs
  - Verfügbarkeit (Ausfallsicherheit, Zuverlässigkeit)
- Zwei Haupttechniken:
  - Data Striping
  - Redundanz

RAID

- Data Striping:
  - Daten werden partitioniert
  - Die Größe einer Partition heißt Striping Unit
  - Verteilung der Daten: bitweise, byteweise oder blockweise
  - Partitionen werden über mehrere Platten verteilt (meist nach Round-Robin-Algorithmus)
- Redundanz: Mehrere Platten → mehrere Fehler
  - Redundante Informationen erlauben Wiederherstellung der Daten im Fehlerfall
  - Entweder Duplikate halten oder nur Kontrollinfos (z.B. Paritätsbits)

RAID Levels – Level 0

- Level 0 – keine Redundanz
  - Datenblöcke werden im Rotationsprinzip auf physische Platten verteilt
  - Striping mit **Block-Granularität**
  - Beste Write-Performance aller RAID-Levels
  - Zuverlässigkeit sinkt linear mit der Anzahl der Platten

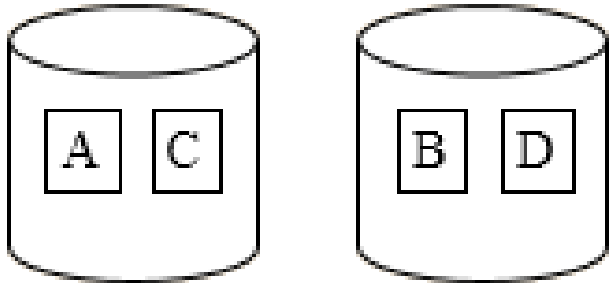

Blöcke: A, B, C, D
2 Platten

RAID Levels – Level 1

- Level 1 – Spiegelung
  - Zwei identische Kopien
  - Jede Platte hat eine Spiegelplatte (Mirror image)
  - Teuerste Lösung: jedes Write muss auf beiden Platten erfolgen
  - Parallele Reads auf verschiedenen Platten möglich
  - Maximale Datentransfer-Rate = Transfer-Rate einer Platte
  - 50%-ige Nutzung des Plattenspeichers

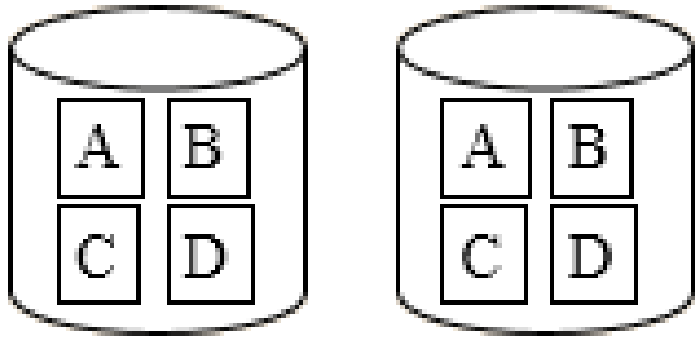

RAID Levels – Level 0+1

- Level 0+1 – Striping und Spiegelung
  - Kombination aus Level 0 (Striping) und Level 1 (Spiegelung)
  - Parallele Read möglich
  - Write-Kosten analog zu Level 1 (beide Platten involviert)
  - Maximale Transfer-Rate = Aggregierte Bandbreite aller Platten

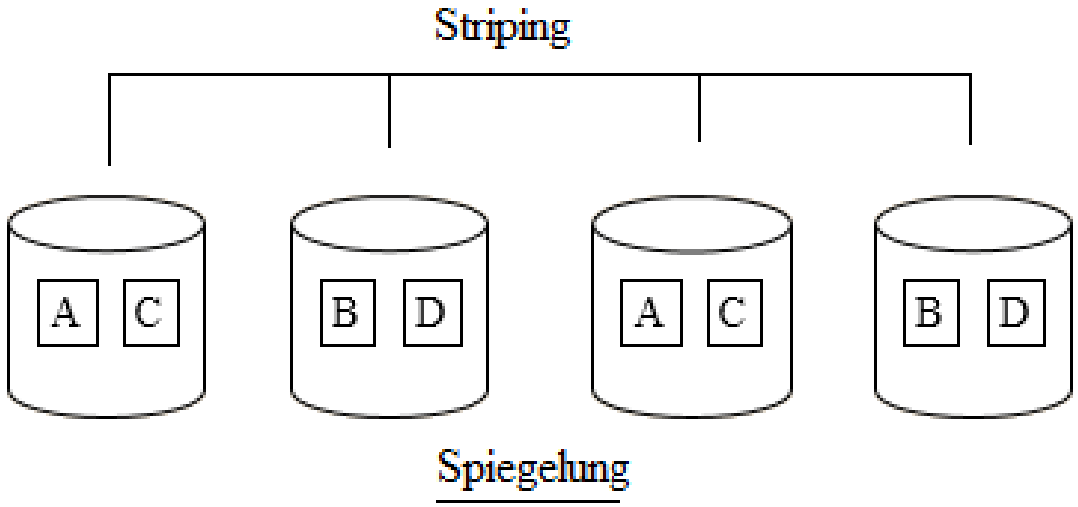

RAID Levels – Level 2

- Level 2 – Error-Correcting Codes
  - Striping auf **Bitebene**
  - Speicherung zusätzlicher Paritätsbits oder Error Correcting Codes (ECC) auf zusätzlichen Platten
  - Regel: 1.Bit auf 1.Platte, ..., i. Bit auf Platte (i mod n); Kontrollinfos auf zusätzlichen Platten
  - Read erfordert 8 parallele Lese-Operationen (für 1 Byte)
  - Zugriff auf einzelne Daten nicht schneller, aber höherer Gesamtdurchsatz (high data transfer rates)
  - Wird in der Praxis nicht benutzt

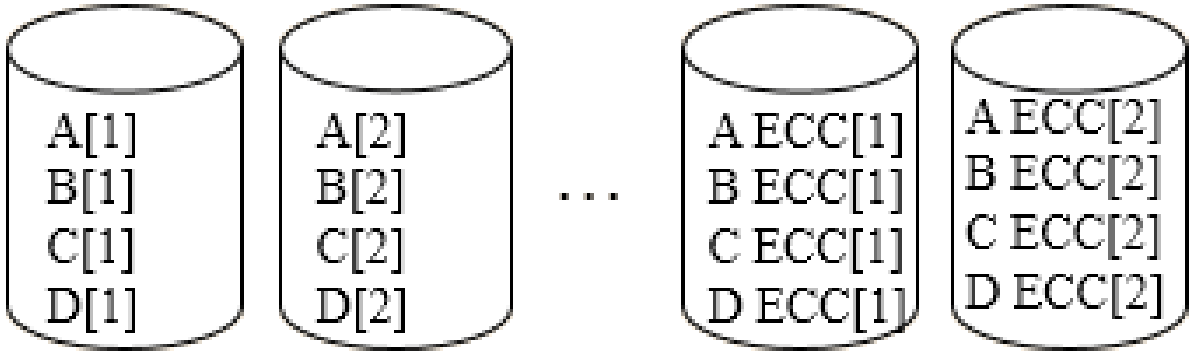

RAID Levels – Level 3

- Level 3 – Bit-Interleaved Parity
  - Striping auf **Bitebene**
  - Nur **eine Check Disk** (ein Paritätsbit ausreichend) → platzsparender als Level2
  - Read und Write erfordern alle Platten
  - Disk Array kann einen Request gleichzeitig verarbeiten
  - Zugriff auf einzelne Daten nicht schneller, aber höher Gesamtdurchsatz

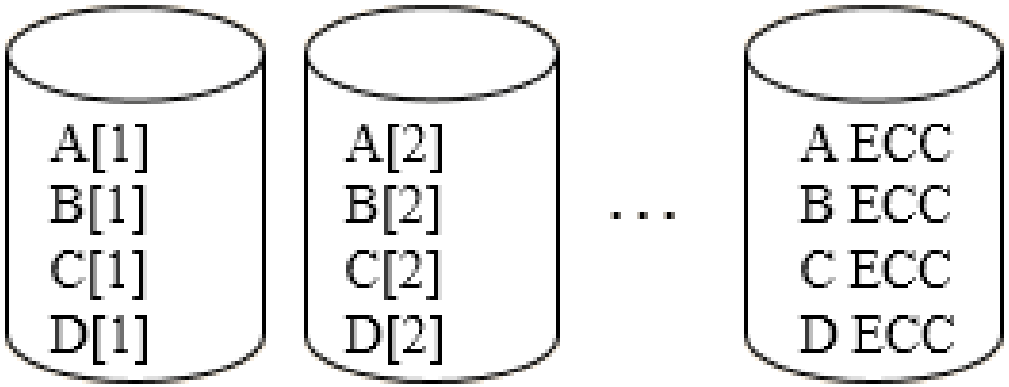

RAID Levels – Level 4

- Level 4 – Block-Interleaved Parity
  - Striping auf **Blockebene**
  - Nur **eine Check Disk** zur Aufnahme des Paritätsbits
  - Kleine Datenmengen können effizienter gelesen werden, da nur eine physische Platte betroffen ist
  - Große Read-Requests können die volle Bandbreite des Disk-Array nutzen
  - Write eines einzelnen Blocks betrifft 2 Platten: Data und Check Disk

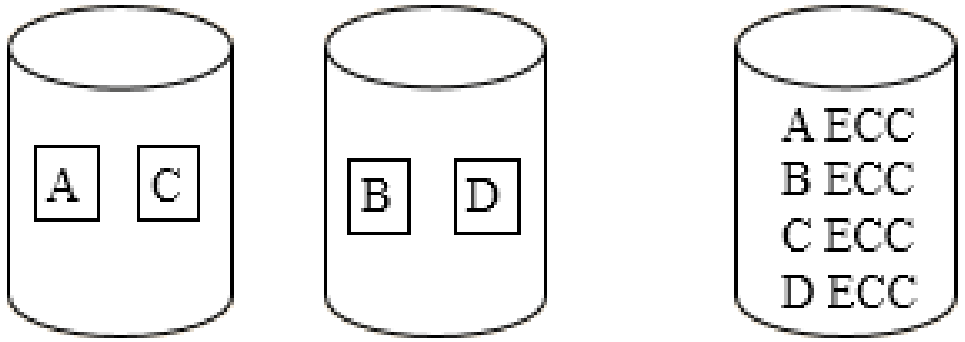

RAID Levels – Level 5

- Level 5 – Block-Interleaved Distributed Parity
  - Ähnlich wie Level 4
  - Blöcke mit den Paritätsbits sind über alle Datenplatten verteilt
  - Vorteile: Write-Requests können ausgeführt werden (kein Bottleneck mehr durch einzige Check Disk); höhere Parallelität beim Lesen (da alle Platten genutzt werde)
  - Beste Performance aller RAID Levels für kleine und große Read-Request und große Write-Requests

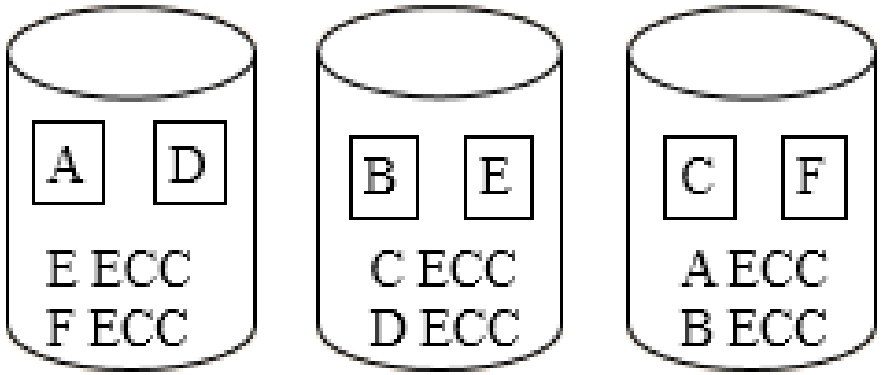

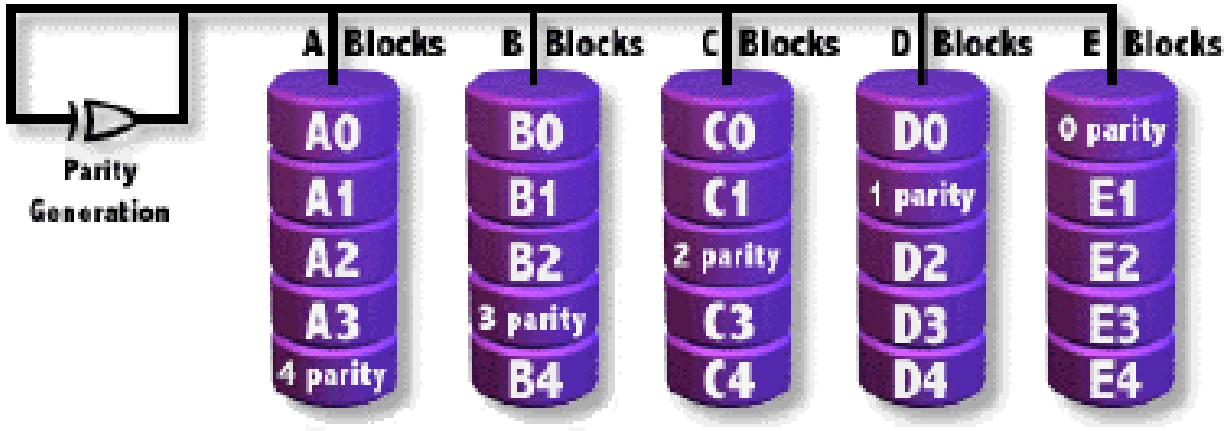

Pufferverwaltung in einem DBMS (Buffer Management)

- Puffer – Hauptspeicher-Bereich fur Kopien von Platten-Blöcken
  - Enthält eine feste Anzahl von Pufferrahmen (Speicherbereiche von der Größe einer Seite)
- Puffer Manager – Subsystem zur Verwaltung des Puffers
  - ähnlich der virtuellen Speicherverwaltung in Betriebssystemen
- Daten müssen im RAM sein, damit DBMS darauf operieren kann
- Programm fragt Puffer Manager an, wenn es einen Block von der Platte braucht

Pufferverwaltung in einem DBMS

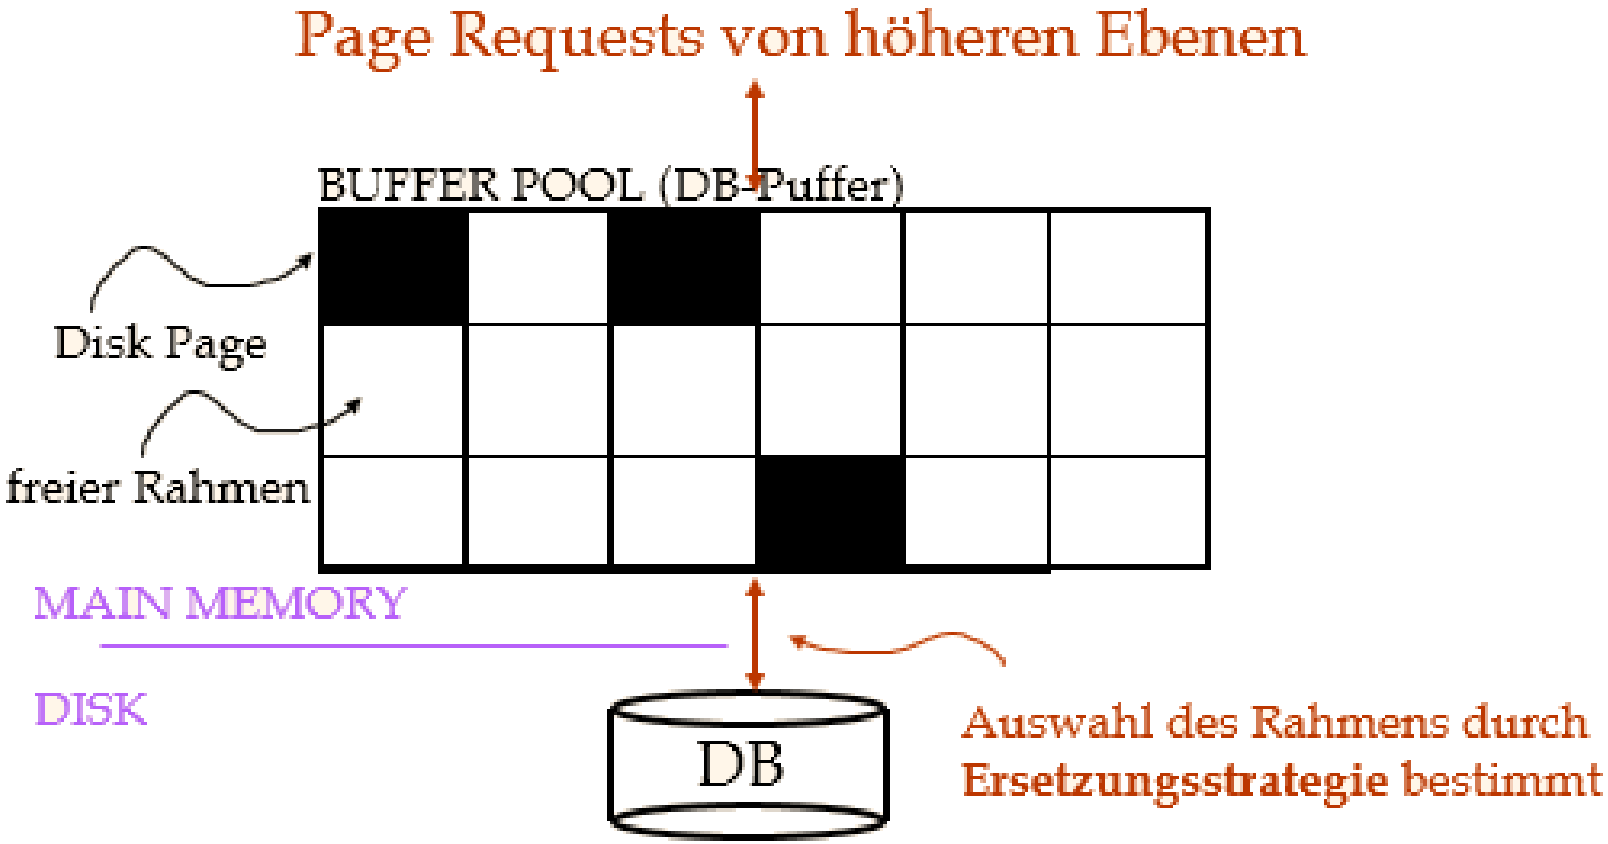

- Tabelle mit <frame#, pageid> pairs wird bewirtschaftet

Wenn eine Seite benötigt wird…

- Wenn die angeforderte Seite nicht im Puffer ist:
  - Auswahl eines Pufferrahmens zur Ersetzung (wenn sämtliche Pufferrahmen belegt) nach einer bestimmten Strategie
  - Ein rausgeworfener Block wird nur auf die Platte geschrieben, falls er seit dem letzten Schreiben auf die Platte geändert wurde (dirty); Anderenfalls kann die betroffene Seite direkt überschrieben werden
  - Einlesen der gesuchten Seite in den gewählten Rahmen
- Rückgabe der Adresse der gelesenen Seite (pin the page and return its address)
- Wenn Requests vorgesehen werden können (z.B. beim sequentiellen Lesen) ist ein Pre-Fetch von Seiten möglich

Pufferverwaltung

- **Pinned Block/Markierte Seite** – darf nicht aus dem Puffer entfernt werden
- Der Requestor unpins eine Seite und gibt an ob die Seite geändert wurde oder nicht – **dirty pin** wird dafür benutzt
- Angeforderte Seiten werden mit einem Verwendungszähler (***pin count***) verwaltet
- Concurrency control & Recovery machen zusätzliche I/O Operationen erforderlich wenn eine Seite im Puffer für Ersetzen ausgewählt wurde (z.B. Write-Ahead Logging Protokoll – vor dem Schreiben einer schmutzigen Änderung in die Datenbank muss die zugehörige Undo-Information in die Log-Datei geschrieben werden)
- Auswahl eines Rahmens zur Ersetzung durch eine Ersetzungsstrategie (replacement policy)

Ersetzungsstrategien für Pufferseiten

- LRU Strategie (least recently used): Ersetzte Block der am längsten nicht benutzt wurde
  - Idee: Zugriffsmuster der Vergangenheit benutzten um zukünfiges Verhalten vorherzusagen
  - Anfragen in DBMSs habe wohldefinierte Zugriffsmuster (z.B. sequentielles Lesen) und das DBMS kann die Information aus den Benutzeranfragen verwenden, um zukünfig benötigte Blöcke vorherzusagen
  - erfolgreich in Betriebssystemen eingesetzt
- MRU Strategie: (most recently used): Ersetze zuletzt benutzten Block als erstes
- Toss Immediate Strategy: Block wird sofort rausgeworfen, wenn das letzte Tupel bearbeitet wurde
- Gemischte Strategien mit Tipps vom Anfrageoptimierer ist am erfolgreichsten

Ersetzungsstrategien für Pufferseiten

- Information im Anfrageplan um zukünftige Blockanfragen vorherzusagen
- Statistik über die Wahrscheinlichkeit, dass eine Anfrage für eine bestimmte Relation kommt
- Strategie hat großen Einfluß auf die Anzahl der I/O Operationen- abhängig vom Zugriffsmuster (access pattern)
- *Sequential Flooding* – verursacht bei LRU + wiederholtes Scannen von Daten
  - Jeder Seiten Request kann eine I/O Operation verursachen
  - MRU ist viel besser in dieser Situation (LRU kann schlecht für bestimmte Zugriffsmuster in Datenbanken sein)

DBMS vs. Filesystem des Betriebssystems

- Betriebssystem umfasst Plattenspeicher- und Puffermanagement

  → warum nicht nutzen für DBMS?
- Es gibt Unterschiede bei den Betriebssystemen → Portabilitätsprobleme
- Beschränkungen: z.B. keine plattenübergreifenden Files
- Puffermanagement erfordert spezielle Fähigkeiten:
  - Markieren (pin) einer Seite im Puffer (inkrementieren Verwendungszähler), Zwingen einer Seite auf Platte (wichtig für Concurrency Control und Recovery)
  - Abstimmung von Ersetzungsstrategien und Unterstützung von Prefetching basierend auf Zugriffsmustern in typischen Datenbankoperationen

Datei aus Sätzen

- Für I/O Operationen genügen Seiten/Blöcke
- Höhere Schichten eines DBMS operieren auf **Sätzen (Records)** und **Dateien aus Sätzen (Files of records)**
- File/Datei:
  - Ansammlung von Seiten, die jeweils eine bestimmte Anzahl von Sätzen enthält
  - Unterstützt folgeden Operationen:
    - Einfügen/Löschen/Modifizieren von Sätzen
    - Lesen eines bestimmten Satzes (spezifiziert durch eine Record-ID)
    - Scannen aller Sätze (möglich mit Einschränkungen auf eine Teilmenge von Sätzen, die zurückgegeben werden sollen)

Satzformate in einem File – Feste Länge

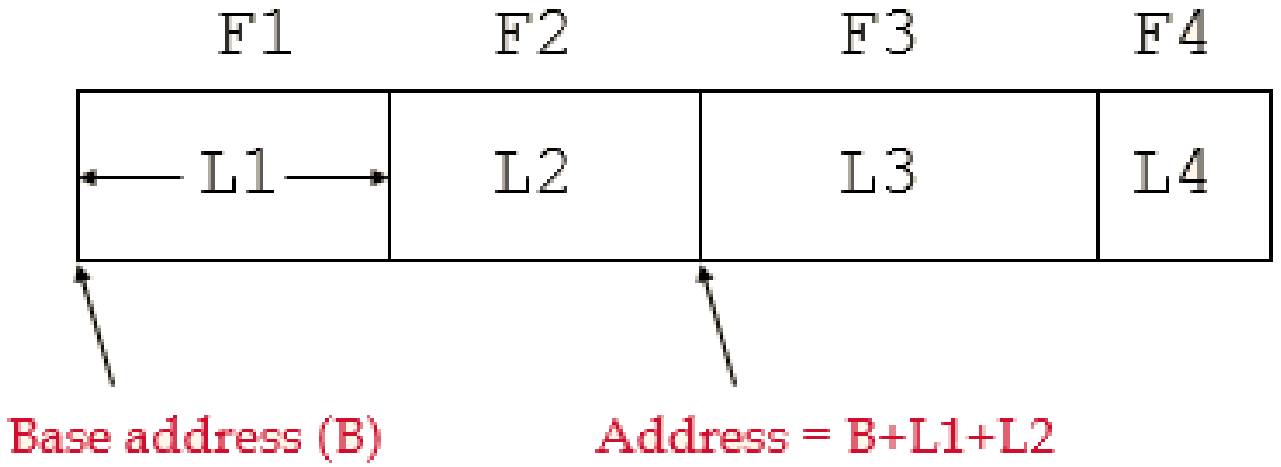

- Informationen über Feldtypen sind gleich für alle Datensätze in einem File
- Finde das i-te Feld erfordert Scannen des Datensatzes

Satzformate in einem File – Variable Länge

- Erstes Format (# Felder ist fix) – Felder getrennt durch spezielle Symbole

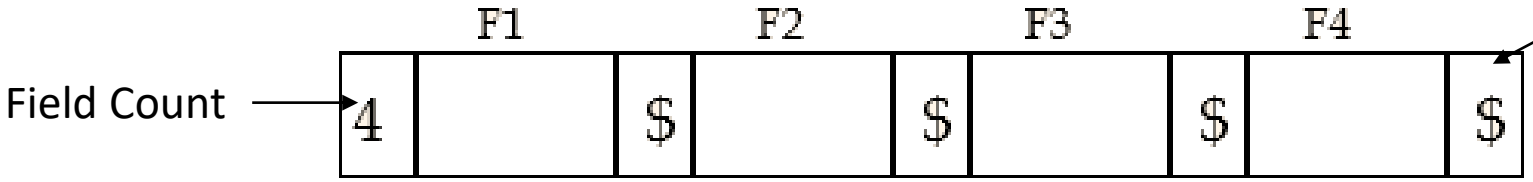

- Zweites Format – Array von Field Offsets
  - erlaubt direkten Zugriff aufs i-te Felds

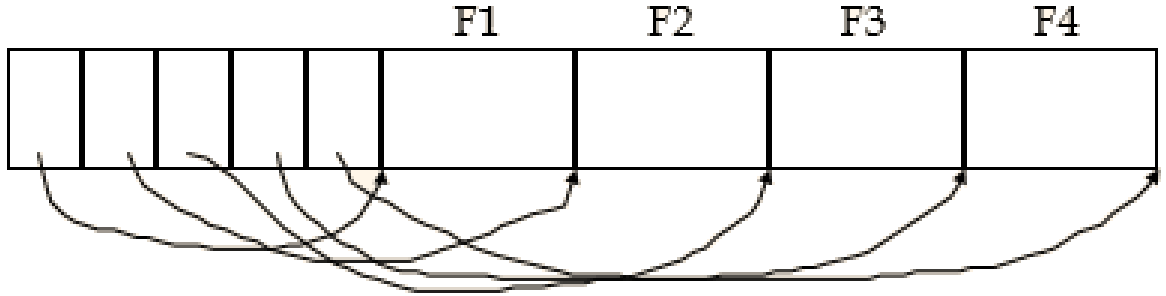

Seitenformate – Sätze fester Länge

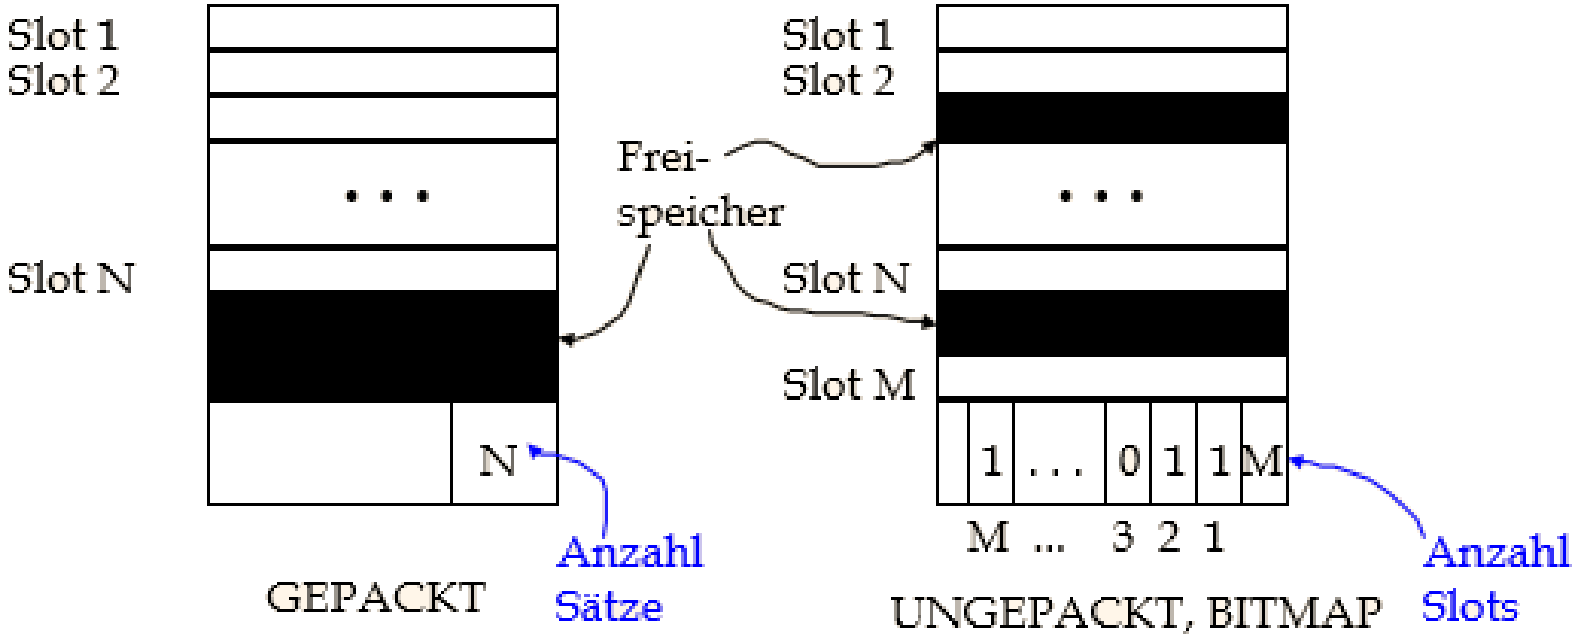

- Record id = <page id, slot #> (Slot = Tupel-Identifikator)
- Erster Ansatz (gepackt): Verschieben von Sätzen in Freispeicher (z.B. Beim Löschen) so dass gilt: Satz i im Slot i. Das ändert jedoch die ID des Satzes (meist nicht akzeptabel)
- Bessere Alternative mit Bitmap

Seitenformate – Sätze variabler Länge

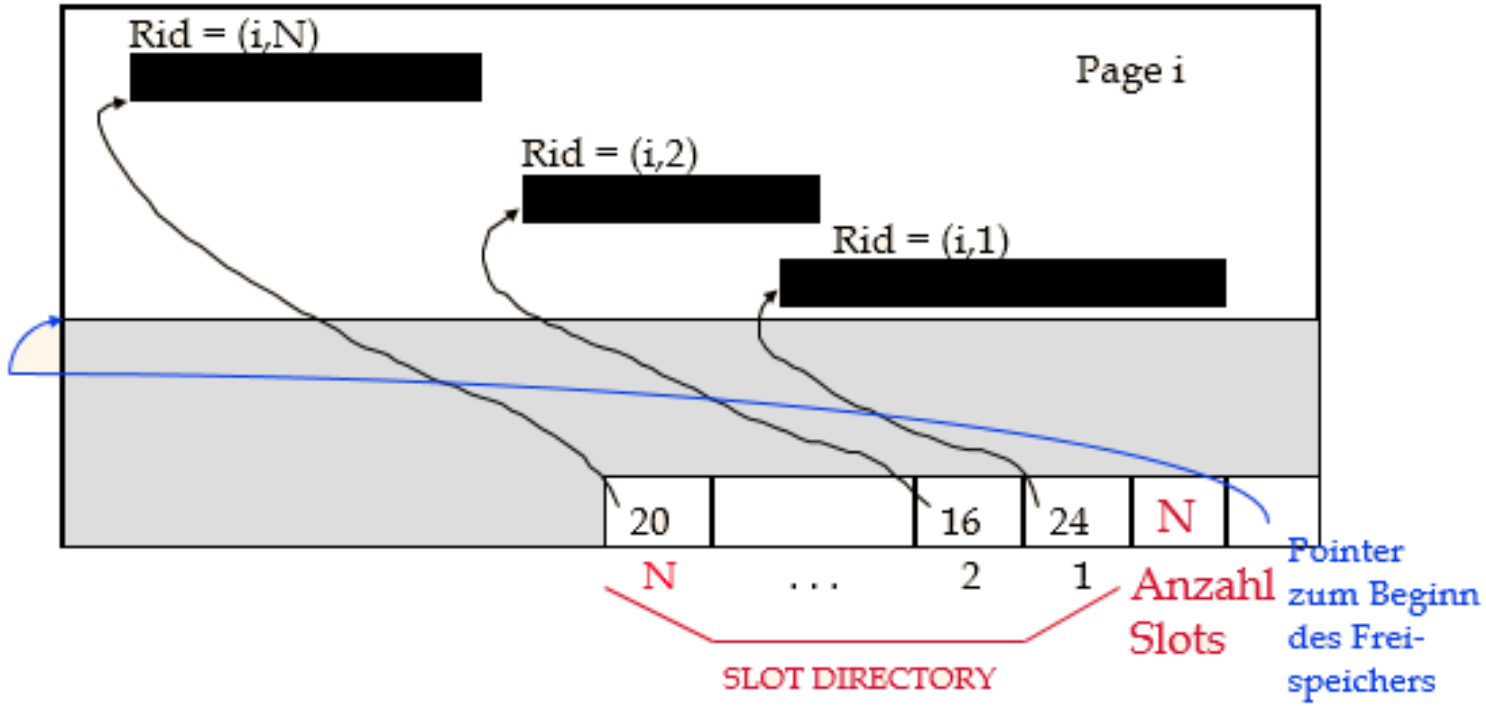

- Verschieben von Sätzen in einer Seite ohne Veränderung der ID möglich (somit auch attraktiv für Sätze fester Länge)
- Im Slot-Directory (Liste von Satz-Zeigern) stehen Offset und Länge für jeden Satz

Organisation von Datensätze

- Verschiedene Ansätze, um Datensätze in Dateien logisch anzuordnen:
  - Heap Datei – ein Datensatz kann irgendwo gespeichert werden, wo Platz frei ist, oder er wird am Ende angehängt
  - Sequentielle/Sortierte Datei – Datensätze werden nach einem bestimmten Datenfeld sortiert abgespeichert
    - Gut für Anwendungen, die sequentiellen Zugriff auf gesamte Datei brauchen
  - Hash Datei
    - Die Datei ist eine Sammlung von Blöcke (buckets)
    - der Hash-Wert für ein Datenfeld bestimmt, in welchem Block (bucket) der Datei der Datensatz gespeichert wird
  - Indexsequentielle Datei (Tree file)
    - Kombination von sequentieller Hauptdatei und Indexdatei
    - Hat die Vorteile der sortierten Dateien (die Nachteile sind nicht so stark)